

Neural Vocoder Training Report

HiFiGAN · LJSpeech · 10 Epochs

Архитектура: **HiFiGAN Generator + MPD + MSD**

Датасет: **LJSpeech-1.1 (22 050 Hz)**

Потери: **Adversarial (LS-GAN) + Feature Matching + Mel-L1**

Оптимизатор: **AdamW (b1=0.8, b2=0.99) LR=2e-4, ExponentialLR g=0.999**

Batch size: **16 | Segment: 8 192 samples**

Эпох обучено: **10 из 300 запланированных**

Архитектура и этапы решения

1. Постановка задачи

Задача - обучить нейронный вокодер, который преобразует мел-спектрограмму в аудиоволну (waveform).

В качестве входного TTS-модуля используется FastPitch (Coqui-TTS), предобученный на LJSpeech. Вокодер должен быть совместим с параметрами FastPitch: 22 050 Hz, 80 мел-банков, hop=256, win=1024.

2. Архитектура генератора (HiFiGAN)

Генератор преобразует мел-спектрограмму $[B, 80, T_{\text{mel}}]$ -> аудио $[B, 1, T_{\text{audio}}]$.

- Pre-conv: Conv1d(80 -> 128, k=7)
- 4 блока апсемплинга с ConvTranspose1d: stride [8, 8, 2, 2], итого x256 (hop_length)
- MRF (Multi-Receptive Field Fusion): 3 параллельных ResBlock на каждом уровне
 - с ядрами [3, 7, 11] и дилатациями [1, 3, 5], результат усредняется
- Post-conv: Conv1d(-> 1) + Tanh для нормировки в [-1, 1]
- Weight Norm на всех сверточных слоях

3. Дискриминаторы

Multi-Period Discriminator (MPD): 5 суб-дискриминаторов с периодами [2, 3, 5, 7, 11]. Каждый анализирует аудио, переформатированное в 2D (time x period), через Conv2d.


Multi-Scale Discriminator (MSD): 3 суб-дискриминатора на разных масштабах (оригинал, x2, x4 downsampling). Первый использует Spectral Norm, остальные - Weight Norm.

4. Функции потерь

Discriminator Loss (LS-GAN): MSE-потеря, реальный -> 1, фейк -> 0.

Потери генератора по эпохам


Суммарная потеря генератора (G Loss)



Adversarial Loss



Feature Matching Loss



Мел-потеря, потеря дискриминатора и скорость обучения


Mel Reconstruction Loss (масштабирован $\lambda=45$)



Discriminator Loss




Learning Rate ($\times 10^4$)



Сводный график всех потерь (нормализованные значения)

Сводный график всех потерь (нормализованные значения)



Анализ метрик и выводы

Динамика потерь генератора

Суммарная потеря G снизилась с 65.21 до 44.86 (-20.34, то есть -31.2%). Наиболее резкое падение наблюдается в первые 3 эпохи, после чего обучение постепенно замедляется.

Mel-L1 потеря (доминирует в G): снизилась с 50.81 до 32.72 (-35.6%). Это ключевой сигнал качества: генератор учится воспроизводить спектральную структуру реального аудио.

Feature Matching: снизился с 9.39 до 7.86. Стабильное снижение говорит о том, что промежуточные активации дискриминатора становятся ближе к реальным, а значит генерируемое аудио становится более реалистичным.

Adversarial Loss: снизился с 5.00 до 4.28. Умеренное снижение показывает, что генератор постепенно начинает обманывать дискриминатор.

Динамика дискриминатора

D Loss вырос с 1.963 до 2.517 (+0.554). Рост потери дискриминатора - это нормальное явление при улучшении генератора: дискриминатору становится сложнее отличить реальное аудио от сгенерированного.

Значения в диапазоне 2-2.5 говорят об активном состоянии GAN-игры, то есть дискриминатор не коллапсирует и не доминирует.

Скорость обучения

LR уменьшается экспоненциально с 0.000200 до 0.000198 ($g=0.999$ за эпоху). После 10 эпох убывание минимально (около 0.1%), что оставляет достаточную гибкость для дальнейшего обучения.

Общие выводы

10 эпох - это лишь начало обучения HiFiGAN (рекомендуется 300+ эпох для высококачественного синтеза).

Положительные тренды во всех метриках подтверждают, что обучение идет корректно.